



UNIVERSIDADE FEDERAL DO CEARÁ
Campus de Sobral

Curso de Engenharia da Computação

Ken Esparta Ccorahua

**APLICAÇÃO DA EXTRAÇÃO DE REGRAS DE UMA REDE
NEURAL NO PROCESSO DE MINERAÇÃO DE DADOS
UTILIZANDO A METODOLOGIA CRISP-DM**

Sobral – CE

2016

Ken Esparta Ccorahua

**APLICAÇÃO DA EXTRAÇÃO DE REGRAS DE UMA REDE NEURAL NO
PROCESSO DE MINERAÇÃO DE DADOS UTILIZANDO A METODOLOGIA
CRISP-DM**

Memorial de Monografia apresentado à disciplina
de Seminário de Monografia do Curso Engenharia
da Computação como requisito parcial para obtenção
do grau de Engenheiro da Computação na
Universidade Federal do Ceará, *Campus* Sobral.

Orientador

Prof. Me. Fernando Rodrigues de Almeida Júnior

Coorientador

Prof. Dr. Márcio André Baima Amora

Sobral – CE, dezembro de 2016

Lista de Figuras

1	Estruturação do conhecimento para conseguir as ferramentas teóricas e técnicas relacionadas com o presente trabalho.	9
2	Principais componentes da família da SC.	10
3	Desenvolvimento da SC.	11
4	Uma visão geral dos passos que compõem o processo KDD.	14
5	Metodologia SEMMA proposto pela SAS.	14
6	Metodologia CRISP-DM, utilizada no presente trabalho.	15
7	Arranjo de sensores utilizado para captar informação do odor do ambiente. . .	18
8	Os sub processos da “Compreensão do projeto”.	18

Lista de Tabelas

- 1 Pesquisa realizada com 200 pessoas sobre qual é a metodologia favorita utilizada nos projetos de mineração de dados, nos anos 2007 e 2014. 15

Lista de abreviaturas e siglas

CRISP-DM	Cross-Industry Standard Process for Data Mining
EC	Evolutionary Computing
FS	Fuzzy Systems
HC	Hard Computing
KDD	Knowledge Discovery From Data
ML	Machine Learning
WEKA	Waikato Environment for Knowledge Analysis
NN	Neural Networks
PR	Probabilistic Reasoning
SEMMA	Sample, Explore, Modify, Model and Assess

Sumário

1	Introdução	5
2	Objetivo	6
2.1	Objetivo geral	6
2.2	Objetivos específicos	6
3	Justificativa	7
4	Trabalhos relacionados	8
5	Fundamentação teórica	9
5.1	Soft computing	9
5.1.1	Computação Evolucionária	11
5.1.2	Sistemas Difusos	11
5.1.3	Raciocínio Probabilístico	11
5.1.4	Rede Neural Artificial	11
5.2	Aprendizado de máquina	11
5.3	Mineração de dados	13
5.3.1	A metodologia KDD	13
5.3.2	A metodologia SEMMA	14
5.3.3	A metodologia CRISP-DM	14
5.4	O software WEKA	15
5.5	Termos relevantes	16
5.5.1	Analista de dados	16
5.5.2	Cientista de dados	16
5.5.3	Big Data	16
5.6	Extração de regras	16
5.6.1	O algoritmo RX	16
5.6.2	O algoritmo C4.5	16
6	Materiais e métodos	17

6.1	Compreensão do projeto	17
6.1.1	Determinar os objetivos do projeto	18
6.1.2	Avaliar a situação	18
6.1.3	Determinar o objetivo da mineração de dados	18
6.1.4	Realizar um plano do projeto	18
6.2	Compreensão dos dados	18
6.2.1	Coletar dados iniciais	19
6.2.2	Descrever os dados	19
6.2.3	Exploração dos dados	19
6.2.4	Verificação da qualidade dos dados	19
6.3	Preparação dos dados	19
6.3.1	Selecionar os dados	19
6.3.2	Limpar os dados	19
6.3.3	Construir dados	19
6.3.4	Integrar dados	19
6.3.5	Formatar os dados	19
6.4	Modelagem	19
6.4.1	Selecionar a técnica de modelagem	19
6.4.2	Gerar um teste	19
6.4.3	Construir o modelo	19
6.4.4	Avaliar o modelo	19
6.5	Avaliação	19
6.5.1	Avaliar os resultados	19
6.5.2	Revisão do processo	19
6.5.3	Determinar os passos a seguir	19
6.6	Desenvolvimento	19
7	Resultados	20
8	Conclusões e recomendações	21
	Referências	22

1 Introdução

2 Objetivo

2.1 Objetivo geral

Mostrar a aplicação da extração de regras na mineração de dados utilizando redes neurais do tipo Backpropagation.

2.2 Objetivos específicos

- Mostrar a base teórica sobre a metodologia de mineração de dados CRISP-DM e sua aplicação.

3 Justificativa

4 Trabalhos relacionados

No relatório técnico intitulado “*Mineração de Dados: Conceitos, Tarefas, Métodos e Ferramentas*”, referenciado em (CAMILO; SILVA, 2009), apresentam-se os conceitos chave, tarefas e métodos essenciais a serem aplicados na mineração de dados. Inclusive são mostradas ferramentas desenvolvidas para tornar o processo de mineração de dados menos técnico; entre essas ferramentas encontra-se o software WEKA que será utilizado no trabalho.

(CHOI et al., 2014)

(BEI et al., 2005)

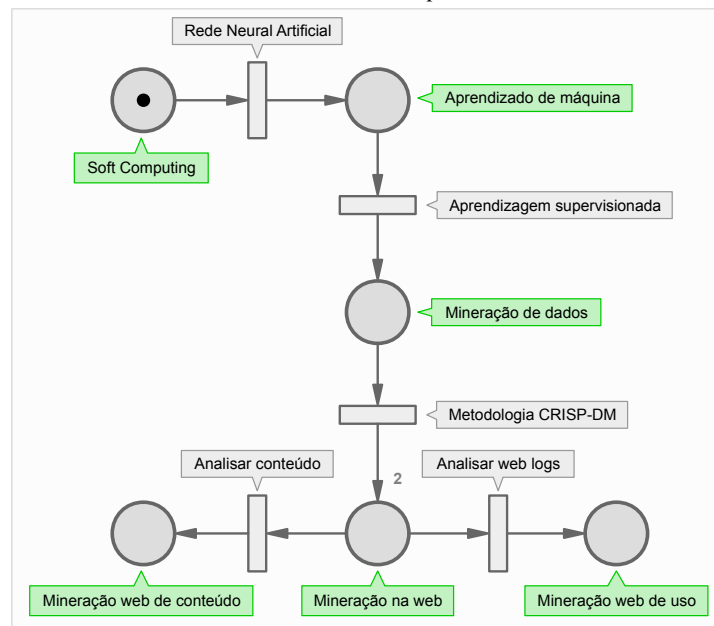
(ZHONG; GUO; SONG, 2008)

5 Fundamentação teórica

A seguir, apresentam-se breves definições sobre os assuntos teóricos relacionados com a monografia, utilizando-se uma abordagem *top-down* como pode-se observar na (FIGURA 1), exibe-se uma rede de Petri que representa a montagem teórica do presente trabalho, na qual o estado inicial é o mais genérico e o estado final é o mais específico.

Na rede de Petri proposta, observa-se também que cada estado representa uma área das Ciências da Computação a qual possui ferramentas teóricas que são adotadas para que a ficha possa ativar as transições. Cada transição representa uma ferramenta que será adquirida do estado anterior antes de passar ao próximo. Em outras palavras, a ficha pode passar somente ao estado seguinte quando uma ferramenta específica do estado anterior é definida para ser utilizada.

Figura 1: Estruturação do conhecimento para conseguir as ferramentas teóricas e técnicas relacionadas com o presente trabalho.



Fonte: Autoria própria.

5.1 Soft computing

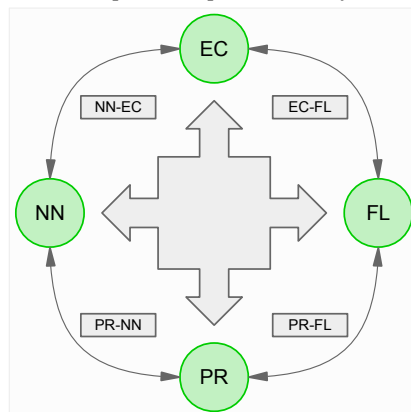
Existem dois tipos de paradigmas computacionais, a Soft Computing (SC) e a Hard Computing (HC), ambos os termos foram estabelecidos pela primeira vez pelo professor L. A. Zadeh no ano 1996. O HC trata sobre modelos precisos em que as soluções são atingidas imediatamente. Por outro lado, a SC lida com modelos de aproximações e dá soluções a problemas complexos (SIVANANDAM; DEEPA, 2004). Como pode-se perceber, a HC é basicamente

a computação convencional de modo que a solução dos problemas baseia-se nos princípios da precisão. Em contraste, o paradigma da SC trata sobre solucionar problemas utilizando modelos imprecisos que possuem certa porcentagem de aproximação.

Cataloga-se a SC em (MAIMON; ROKACH, 2007) como uma coleção de novas técnicas em inteligência artificial que exploram a tolerância para a imprecisão, incerteza, verdade parcial e manipulação de não linearidades para poder alcançar rastreabilidade, robustez e soluções de menor custo comparado com os métodos da HC, ou seja, apresenta-se uma coleção de ferramentas aptas para minerar a Web porque esta encaixa-se nas definições de imprecisão, incerteza e veracidade duvidosa.

A SC é composta por técnicas como as Redes Neurais (Neural Networks), Computação Evolucionária (Evolutionary Computing), Sistemas Difusos (Fuzzy Systems) e Raciocínio Probabilístico (Probabilistic Reasoning), como mostrado na (FIGURA 2).

Figura 2: Principais componentes da família da SC.

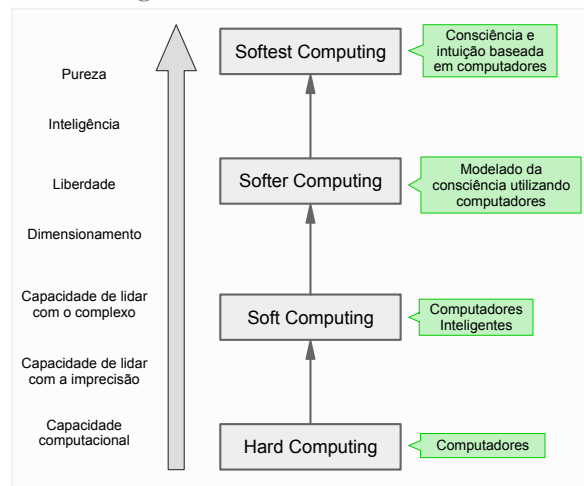


Fonte: Adaptado de (MANKAD, 2013).

As técnicas mostradas na (FIGURA 2), nem sempre estão isoladas. Elas podem ser combinadas para resolver um mesmo problema, e isso denomina-se hibridação.

Em (ZADEH, 1996) define-se a SC como uma nova abordagem da computação a qual é análoga à habilidade marcante da mente humana para pensar e aprender sobre um entorno incerto e impreciso. A SC, segundo (CHATURVEDI, 2008), é uma vertente da computação na qual pretende-se construir máquinas inteligentes e sábias. Pode-se observar na (FIGURA 3) o desenvolvimento da SC, começando pela computação convencional, até chegar ao extremo de pensamento puro por parte de um computador, ou seja, o objetivo final da SC é projetar e desenvolver um computador que possa agir de forma semelhante aos seres humanos.

Figura 3: Desenvolvimento da SC.



Fonte: Adaptado de (CHATURVEDI, 2008).

5.1.1 Computação Evolucionária

5.1.2 Sistemas Difusos

5.1.3 Raciocínio Probabilístico

5.1.4 Rede Neural Artificial

Uma rede neural artificial (ou simplesmente rede neural) é um modelo matemático simplificado de uma rede de neurônios biológicos. A unidade fundamental de uma rede neural é o neurônio que está interconectado com outros. Essas redes executam em paralelo uma tarefa global comum e possuem a habilidade de aprendizagem. Explica-se em (MANKAD, 2013) que uma consequência da aprendizagem dos neurônios de uma rede neural é a aquisição de conhecimento de modo a torná-lo disponível para o uso. As características básicas de uma rede neural são o paralelismo inerente, acesso à informação local, a semelhança entre suas componentes e o aprendizado incremental.

A rede neural utilizada no trabalho é do tipo perceptron de múltiplas camadas, com algoritmo de treinamento Levenberg Marquard.

5.2 Aprendizado de máquina

A ficha encontra-se no seguinte estado, contendo já a teoria de uma rede neural. Nesta seção trata-se sobre as técnicas que serão adotadas do aprendizado de máquina (Machine Learning, ou ML).

O aprendizado automático ou aprendizado de máquina é um programa de computa-

dor que pode “aprender” de um conjunto de entradas disponíveis. Define-se, em (MURPHY, 2012), que o aprendizado de máquina é um conjunto de métodos que podem detectar automaticamente padrões em um determinado conjunto de dados e, posteriormente, utilizar esses padrões descobertos para prever dados futuros. Aprendizado é, grosseiramente falando, o processo de converter experiência em habilidade ou conhecimento (SHALEV-SHWARTZ; BEN-DAVID, 2014). Aprender a partir de dados é o conceito fundamental do ML.

O foco do ML é a modelagem do aprendizado e a adaptação (atividades de animais e humanos) num computador. Os métodos do ML são denominados “sub-simbólicos” porque não existem símbolos ou manipulação deles envolvidos, em contraste com a Inteligência Artificial, em que o computador manipula símbolos que refletem o entorno (processo simbólico) (MARSLAND, 2015).

Tomando como ponto de partida que as máquinas aprendem a partir de dados, então, em (MARSLAND, 2015) a ML trata sobre como fazer computadores modificarem ou adaptarem as suas ações de modo que estas se tornem mais precisas. A precisão é medida por quão bem a escolha de ações refletem as escolhas corretas.

Saber em que momento precisa-se do ML é fundamental porque justifica a utilização dos conceitos de ML no trabalho. Em (SHALEV-SHWARTZ; BEN-DAVID, 2014), sugere-se que os conceitos de ML devem ser utilizados em tarefas realizadas por humanos ou animais. De acordo com isso, precisa-se do ML para poder modelar os algoritmos deste trabalho, de modo que utilizam-se dados gerados pela interação humana com a Web a partir de buscas.

De acordo com (MURPHY, 2012), o aprendizado de máquina divide-se, usualmente, em aprendizado supervisionado, aprendizado não supervisionado e aprendizado por reforço. Na abordagem supervisionada ou preditiva do ML, tem-se como objetivo o aprendizado mapeando as saídas a partir das entradas, dado um conjunto de treinamento. A segunda abordagem de ML, a não supervisionada ou descritiva, tem como objetivo encontrar padrões e correlações entre os dados. Finalmente, a abordagem de aprendizado por reforço, trata-se do modo de agir ou se comportar diante de uma situação de recompensa ou de punição.

A atividade de extrair conhecimento a partir do banco de dados justifica a escolha da utilização das ferramentas oferecidas pela abordagem supervisionada do aprendizado de máquina. Então, a ficha da rede de Petri passa para o seguinte estado sabendo que até esta subseção, juntando os conceitos revisados, está sendo utilizada uma rede neural com aprendizagem supervisionada.

5.3 Mineração de dados

A mineração de dados é definida, segundo (ZAKI; JR., 2014), como o processo de descoberta intuitiva de novos padrões de interesse, assim como modelos preditivos, descritivos e compreensíveis.

Em (RAJARAMAN; LESKOVEC; ULLMAN, 2012) descreve-se a mineração de dados como a descoberta de modelos a partir de dados. Existem duas abordagens: a estatística e a do aprendizado de máquina. Para o presente trabalho utiliza-se a abordagem de aprendizado de máquina, esta decisão justifica-se na (SUBSEÇÃO 5.2).

Uma analogia da mineração de dados faz-se em (HAN; PEI, 2012), com a obtenção de ouro puro a partir da extração de toneladas de rochas em uma mina. Ademais, enfatiza-se que o nome apropriado para mineração de dados é “conhecimento minerado a partir de dados”.

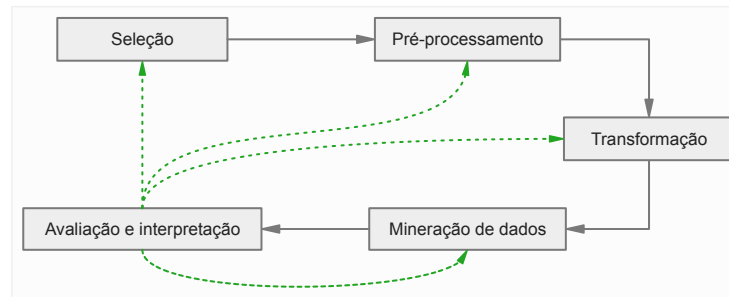
Segundo (HAN; PEI, 2012), a descoberta de conhecimento a partir de dados (ou KDD, do inglês Knowledge Discovery from Data) é sinônimo de mineração de dados, não obstante em (SHAFIQUE; QAISER, 2014) coloca-se o KDD, juntamente com o CRISP-DM e o SEMMA, como um tipo de processo relacionado com a mineração de dados. A seguir, expõe-se uma breve descrição sobre eles:

5.3.1 A metodologia KDD

É um modelo de processo que consiste na extração de conhecimentos escondidos a partir de um banco de dados. Deve ser um processo iterativo e iterativo, e possui cinco passos de desenvolvimento que se podem observar na (FIGURA 4).

Em (ZAPATA; GIL, 2011), menciona-se que a mineração de dados existia como uma fase do processo KDD. A mineração de dados só compreendia a aplicação de algoritmos de otimização e classificação, mas com o tempo evoluiu e atualmente refere-se ao processo completo de KDD.

Figura 4: Uma visão geral dos passos que compõem o processo KDD.

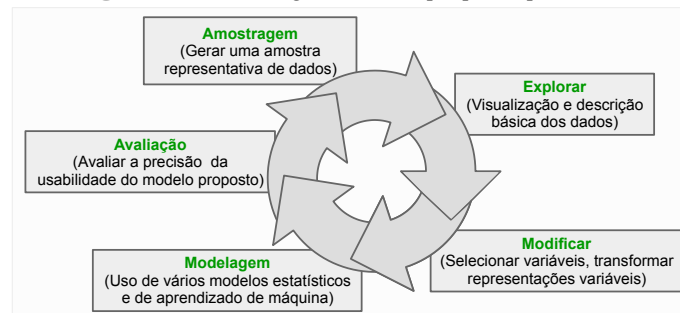


Fonte: Adaptado de (FAYYAD; PIATETSKY-SHAPIO; SMYTH, 1996).

5.3.2 A metodologia SEMMA

Do acrônimo Sample, Explore, Modify, Model and Assess; que foi desenvolvido pelo instituto SAS¹. Foca-se basicamente no desenvolvimento e manutenção de projetos de mineração de dados. Consiste em um ciclo altamente iterativo de cinco passos como pode-se verificar na (FIGURA 5).

Figura 5: Metodologia SEMMA proposto pela SAS.



Fonte: Adaptado de (BINUS, 2014).

5.3.3 A metodologia CRISP-DM

É um processo de mineração de dados que significa Cross-Industry Standard Process for Data Mining. Segundo (CHAPMAN et al., 2000), o processo foi concebido no ano 1996 pelas empresas DaimlerChrysler², SPSS³ e NCR⁴. É uma ferramenta que está constituída por seis processos cíclicos como se mostra na (FIGURA 6). Segundo a pesquisa de (PIATETSKY,

¹ Statistical Analysis System, é o nome de uma empresa pioneira em Business intelligence. Disponível em <<http://www.sas.com>>

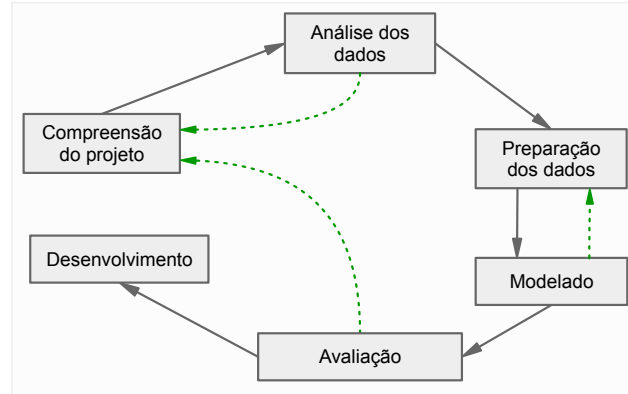
² É um fabricante de automóveis de passageiros e veículos comerciais. Disponível em <<https://www.daimler.com>>

³ É um software para análise estatística de dados, disponível em <<http://www.ibm.com/analytics/us/en/technology/spss/>>

⁴ É uma empresa de tecnologia especializada em produtos para o varejo e setores financeiros, disponível em <<http://www.ncr.com>>

2014) no site KDnuggets, pode-se observar na (TABELA 1) que o CRISP-DM é o método mais utilizado nos anos 2007 e 2014.

Figura 6: Metodologia CRISP-DM, utilizada no presente trabalho.



Fonte: Adaptado de (OLSON; DELEN, 2008).

Tabela 1: Pesquisa realizada com 200 pessoas sobre qual é a metodologia favorita utilizada nos projetos de mineração de dados, nos anos 2007 e 2014.

Metodologia	Ano 2007 (%)	Ano 2014 (%)
CRISP-DM	42.0	43.0
Criada por mim	19.0	27.5
SEMMA	13.0	8.5
Outra	4.0	8.0
Processo KDD	7.3	7.5
Criada pela organização onde trabalho	5.3	3.5
Específica de domínio	4.7	2.0
Nenhuma	4.7	0.0

Fonte: Adaptado de (PIATETSKY, 2014).

Para passar ao seguinte estado da rede de Petri estabelecida, de acordo com a (FIGURA 1), é necessário adotar um tipo de processo de mineração de dados. Como é mencionado em (OLSON; DELEN, 2008), nas três metodologias que foram consideradas, não há obrigação de seguir de forma rígida seus respectivos passos. Afinal, optou-se por seguir a metodologia CRISP-DM. Na (SEÇÃO 6) vê-se a aplicação desta metodologia a partir do ponto de vista da proposta do trabalho.

5.4 O software WEKA

5.5 Termos relevantes

5.5.1 *Analista de dados*

5.5.2 *Cientista de dados*

5.5.3 *Big Data*

5.6 Extração de regras

5.6.1 *O algoritmo RX*

5.6.2 *O algoritmo C4.5*

6 Materiais e métodos

Se situando no contexto deste trabalho, o autor, cumpre dois papéis diferentes: um de cliente e outro de analista de dados. Cumprindo o papel de cliente, dispõe-se de uma massa de dados relacionada com o artigo referenciado em (HUERTA et al., 2016) e disponível no site da UCI⁵. Em contrapartida, cumprindo o papel de analista de dados, aplica-se a metodologia CRISP-DM à massa de dados disponibilizada pelo cliente.

Tendo em conta o exposto no parágrafo prévio, plantea-se a seguinte situação: o cliente deseja obter conhecimento relevante dos dados que possui⁶, então ele pede a um analista de dados para que possa realizar o trabalho relacionado com obtenção de conhecimento a partir dos dados.

Depois de gerar o contexto no qual a ação de minerar dados é realizada, aprofundam-se nas etapas do processo da metodologia CRISP-DM para que a mineração dos dados do cliente seja satisfatória. Em (CHAPMAN et al., 2000) mostra-se, de forma detalhada, o modelo de referência da metodologia CRISP-DM. Este modelo possui seis etapas que são aplicadas no processo de mineração do conjunto de dados proporcionados pelo cliente.

6.1 Compreensão do projeto

O primeiro objetivo do analista de dados é compreender, o que o cliente realmente deseja fazer com os dados que dispõe. O objetivo do analista é descobrir, no início, fatores importantes que possam influenciar o resultado do projeto.


Neste trabalho, o cliente possui uma massa de dados relacionada com sensores químicos que podem detectar diferentes tipos de odor. Esses sensores são oito e formam uma “nariz eletrônica” como mostrado na (FIGURA 7). Utilizando a nariz eletrônica, coletaram-se dados durante 537 dias em um ambiente fechado como mencionado em (HUERTA et al., 2016), esses dados representam uma grande variedade de eventos presentes em cenários de monitoramento domiciliar.

Em este caso particular, o cliente deseja saber se existe algum tipo de regra lógica que relacione os valores da condutância (em Ω^{-1}) dos oito sensores e os tipos de odor. Os tipos de odores são dois: de banana e de vinho, ademais existe outro tipo chamado de “background”

⁵É uma organização que dispõe, de forma gratuita, massas de dados com suas respectivas referências, disponível em <<http://archive.ics.uci.edu/ml/datasets.html>>

⁶Ressaltando que o cliente não é quem gerou os dados. A massa de dados foi obtida de <<http://archive.ics.uci.edu/ml/datasets/Gas+sensors+for+home+activity+monitoring>>


Figura 7: Arranjo de sensores utilizado para captar informação do odor do ambiente.



Fonte: Adaptado de (HUERTA et al., 2016).

que é inodoro. Na (SUBSEÇÃO 6.2) são apresentados, de forma detalhada, os metadados e os dados referentes ao banco de dados fornecido pelo cliente. Na (FIGURA 8) mostra-se os quatro subprocessos relacionados à compreensão do projeto por parte do analista de dados.

Figura 8: Os sub processos da “Compreensão do projeto”.



Fonte: Adaptado de (CHAPMAN et al., 2000).

6.1.1 Determinar os objetivos do projeto

6.1.2 Avaliar a situação

6.1.3 Determinar o objetivo da mineração de dados

6.1.4 Realizar um plano do projeto

6.2 Compreensão dos dados

A massa de dados na qual vai ser aplicada a metodologia CRISP-DM está relacionada com sensores químicos que podem detectar diferentes tipos de odor. No caso deste projeto, esses tipos de odores são dois: o de banana e o de vinho. Além desses dois odores, existe outro chamado de “background” que é do tipo inodoro.

6.2.1 *Coletar dados iniciais*

6.2.2 *Descrever os dados*

6.2.3 *Exploração dos dados*

6.2.4 *Verificação da qualidade dos dados*

6.3 **Preparação dos dados**

6.3.1 *Selecionar os dados*

6.3.2 *Limpar os dados*

6.3.3 *Construir dados*

6.3.4 *Integrar dados*

6.3.5 *Formatar os dados*

6.4 **Modelagem**

Rede Neural.

6.4.1 *Selecionar a técnica de modelagem*

6.4.2 *Gerar um teste*

6.4.3 *Construir o modelo*

6.4.4 *Avaliar o modelo*

6.5 **Avaliação**

6.5.1 *Avaliar os resultados*

6.5.2 *Revisão do processo*

6.5.3 *Determinar os passos a seguir*

6.6 **Desenvolvimento**

Pôr em prática o modelo desenvolvido, não vai ser realizado no presente trabalho

7 Resultados

8 Conclusões e recomendações

Referências

- BEI, A. et al. Research and improvement of splitting rule extraction data mining algorithm based on neural networks. *Engineering in Medicine and Biology 27th Annual Conference*, 2005.
- BINUS. *Processes in Data Mining*. 2014. Disponível em: <<http://sisbinus.blogspot.com.br/2014/11/processes-in-data-mining.html>>. Acesso em: 10 jun. 2016.
- CAMILO, C. O.; SILVA, J. C. da. *Mineração de Dados: Conceitos, Tarefas, Métodos e Ferramentas*. [S.l.], 2009.
- CHAPMAN, P. et al. *CRISP-DM 1.0: Step-by-step data mining guide*. [S.l.], 2000.
- CHATURVEDI, D. K. *Soft Computing: Techniques and its Applications in Electrical Engineering*. [S.l.]: Springer, 2008.
- CHOI, J.-K. et al. Study on datamining techniqe for foot disease prediction. *IT Convergence and Security (ICITCS), 2014 International Conference*, 2014.
- FAYYAD, U.; PIATETSKY-SHAPIO, G.; SMYTH, P. From data mining to knowledge discovery in databases. *AI MAGAZINE*, 1996.
- HAN, J.; PEI, M. K. J. *Data Mining Concepts and Techniques*. 3rd. ed. [S.l.]: ELSEVIER, 2012.
- HUERTA, R. et al. Online decorrelation of humidity and temperature in chemical sensors for continuous monitoring. *Chemometrics and Intelligent Laboratory Systems*, 2016.
- MAIMON, O.; ROKACH, L. *Soft Computing for Knowledge Discovery and Data Mining*. [S.l.]: Springer, 2007.
- MANKAD, K. B. *A Genetic-Fuzzy Approach to Measure Multiple Intelligence*. Dissertação (Mestrado) — Sardar Patel University, 2013.
- MARSLAND, S. *Machine Learning: An Algorithmic Perspective*. [S.l.]: CRC Press, 2015.
- MURPHY, K. P. *Machine Learning: A Probabilistic Perspective*. [S.l.]: Massachusetts Institute of Technology, 2012.
- OLSON, D. L.; DELEN, D. *Advanced Data Mining Techniques*. [S.l.]: Springer, 2008.
- PIATETSKY, G. *CRISP-DM, still the top methodology for analytics, data mining or data science projects*. 2014. Disponível em: <<http://www.kdnuggets.com/2014/10/crisp-dm-top-methodology-analytics-data-mining-data-science-projects.html>>. Acesso em: 10 jun. 2016.
- RAJARAMAN, A.; LESKOVEC, J.; ULLMAN, J. D. *Mining of Massive Datasets*. [S.l.]: Stanford University, 2012.
- SHAFIQUE, U.; QAISER, H. A comparative study of data mining process models (kdd, crisp-dm and semma). *International Journal of Innovation and Scientific Research*, 2014.

- SHALEV-SHWARTZ, S.; BEN-DAVID, S. *Understanding Machine Learning: From Theory to Algorithms*. [S.l.]: Cambridge University Press, 2014.
- SIVANANDAM, S. N.; DEEPA, S. N. *Principles of Soft Computing*. [S.l.]: Wiley, 2004.
- ZADEH, L. A. The roles of soft computing and fuzzy logic in the conception, design and deployment of intelligent system. *IEEE Intelligent Systems*, 1996.
- ZAKI, M. J.; JR., W. M. *Data Mining and Analysis Fundamental Concepts and Algorithms*. [S.l.]: Cambridge University Press, 2014.
- ZAPATA, C. M.; GIL, N. Incorporation of both pre-conceptual schemas and goal diagrams in crisp-dm. *Computing Congress*, 2011.
- ZHONG, L.; GUO, C.; SONG, H. Research and improvement of splitting rule extraction data mining algorithm based on neural networks. *International Conference on Computer Science and Software Engineering*, 2008.